

Universidad de Concepción

Facultad de Ingeniería

Departamento Ingeniería Civil Informática

Tarea 1: Escape de la Torre

Asignatura: Inteligencia Artificial

Integrante: Agustín Salgado Espinoza

Enlace Repositorio: <https://github.com/elamiql/Tarea-1-IA.git>

Introducción

La tarea consiste en modelar un escenario de evacuación de un edificio en el contexto de un incendio, donde un conjunto de agentes debe alcanzar una única salida antes de ser alcanzados por el fuego. El problema incorpora condiciones dinámicas como propagación irreversible del fuego, congestión producida por la concentración de agentes y necesidad de replanificar rutas cuando una zona previamente transitada queda bloqueada.

Para abordar el problema se implementaron cinco algoritmos pertenecientes a tres paradigmas distintos de IA: dos métodos de búsqueda no informada, dos métodos de búsqueda informada y un algoritmo metaheurístico basado en algoritmos genéticos.

El objetivo del trabajo es comparar experimentalmente el comportamiento de estas estrategias en distintos escenarios, considerando principalmente la tasa de supervivencia de los agentes y el tiempo requerido para completar la evacuación.

Modelado del Problema

El entorno se representa como una grilla de 50x50 celdas. Cada celda puede ser transitable o corresponder a un obstáculo. Los agentes inicialmente ocupan distintas posiciones transitables del mapa y deben alcanzar una única salida de evacuación.

Los agentes pueden realizar cinco acciones discretas, desplazarse hacia arriba, abajo, derecha, izquierda y esperar. No se permiten movimientos en diagonal. Esta representación coincide con las restricciones establecidas en el enunciado.

Propagación del Fuego

El incendio comienza desde una celda transitable seleccionada para cada escenario. El fuego se expande ortogonalmente una capa cada k turnos, utilizando en los experimentos $k = 5$.

Las celdas alcanzadas por el fuego permanecen quemadas durante el resto de la simulación y pasan a considerarse intransitables. Si el fuego alcanza a un agente antes de que evacúe, este se considera muerto.

El fuego se encuentra activo desde el turno 0 y, cada $k = 5$ turnos, avanza una capa hacia las celdas transitables ortogonalmente adyacentes. Los obstáculos impiden su propagación.

Al comienzo de cada turno se actualiza primero el estado del incendio, si un agente se encuentra sobre una celda alcanzada por el fuego antes de realizar su movimiento, se considera muerto. Si el fuego alcanza la única salida, los agentes que todavía permanecen dentro ya no pueden evacuar.

Para determinar el horizonte de la simulación se calcula mediante BFS la distancia mínima d_f que debe recorrer el fuego desde su origen hasta la salida. Debido a que el incendio avanza una capa cada k turnos, el turno en que alcanza la salida corresponde a:

$$T_{salida} = d_f \cdot k$$

De esta forma, el horizonte depende de la geometría de cada escenario y no de una cantidad arbitraria de turnos.

Como se incluye también el turno en que el fuego alcanza la salida, el horizonte utilizado por la simulación y por el Algoritmo Genético corresponde a $H = T_{salida} + 1$.

Congestión

La congestión se modela según la cantidad de agentes que ocupan simultáneamente una misma celda. Si una celda contiene cero o un agente no existe penalización adicional. Para dos o más agentes se utiliza una función cuadrática:

$C(n) = (n - 1)^2$, donde n corresponde al número de agentes presentes simultáneamente en la celda.

Se escogió $C(n) = (n - 1)^2$ ya que asumimos que la celda soporta a 1 agente sin congestión. Entonces no “castigamos” al primer agente, sino el exceso sobre la capacidad base de 1.

El costo total de congestión de una simulación corresponde a la suma del costo generado por todas las celdas durante todos los turnos.

En el caso particular de A*, la congestión también influye directamente en la planificación de la ruta. El costo de desplazarse hacia una celda v se calcula como:

$$c(u, v) = 1 + 5 \cdot O_{t-1}(v)$$

donde $O_{t-1}(v)$ corresponde a la cantidad de agentes que ocuparon la celda v durante el turno anterior. Por lo tanto, una celda que estuvo más ocupada adquiere un mayor costo y A* puede preferir una ruta alternativa. El costo mínimo de cualquier movimiento continúa siendo 1 y la congestión únicamente puede aumentarlo, por lo que la distancia Manhattan sigue siendo una heurística admisible.

El factor 5 se fijó como parámetro de diseño para que la ocupación previa tuviera una influencia apreciable sobre el costo de movimiento, manteniendo al mismo tiempo el costo base de desplazamiento igual a 1. Este valor se mantuvo constante durante todos los experimentos.

BFS, DFS y Greedy no utilizan la congestión para seleccionar sus rutas; sin embargo, el costo de congestión generado por ellos igualmente se registra como métrica experimental.

Algoritmos Implementados

Breadth-First Search – BFS

Corresponde a un algoritmo de búsqueda no informada que explora el espacio por niveles. Se utiliza una cola FIFO (deque) que inicialmente contiene la posición del agente. Cada nodo extraído de la cola incorpora sus vecinos transitables que no han sido visitados.

Cuando se alcanza el nodo salida, el camino se reconstruye siguiendo la relación entre el nodo y su padre.

Debido a que los movimientos de la grilla tienen costo unitario, BFS encuentra una ruta con el mínimo número de movimientos entre la posición inicial y la salida.

Depth-First Search – DFS

Corresponde a un algoritmo de búsqueda no informada, utiliza una pila LIFO en lugar de una cola. Esto provoca que el algoritmo profundice en una dirección antes de explorar sus alternativas.

Al igual que BFS, mantiene un conjunto de posiciones visitadas y un registro de padres para reconstruir la ruta encontrada.

DFS no garantiza que la primera ruta encontrada sea la más corta. Como consecuencia, un agente puede recibir una ruta considerablemente más larga que otra disponible.

A*

Es un algoritmo de búsqueda informada que combina el costo acumulado desde el origen con una estimación del costo restante: $f(n) = g(n) + h(n)$.

Donde $g(n)$ corresponde al costo acumulado hasta el nodo actual y $h(n)$ corresponde a la estimación de la distancia desde el nodo hasta la salida.

Se utilizó como heurística la distancia Manhattan $h(n) = |x_n - x_s| + |y_n - y_s|$

Esta heurística es admisible bajo movimientos ortogonales porque nunca sobreestima la cantidad mínima de desplazamientos requeridos para alcanzar la salida.

Greedy Best-First Search

Este algoritmo utiliza igualmente la distancia Manhattan, pero su elección de nodos depende exclusivamente de $h(n)$.

A diferencia de A*, no considera un costo acumulado $g(n)$. Por lo tanto, siempre prioriza aquel nodo que parece encontrarse más cerca de la salida según la heurística.

Esto permite dirigir rápidamente la búsqueda hacia el objetivo, aunque no asegura encontrar el camino de menor costo.

Replanificación durante la simulación

Durante la simulación, BFS, DFS, A* y Greedy Best-First no calculan una única ruta al comienzo y la siguen hasta el final. Cada agente planifica inicialmente desde su posición hasta la salida y vuelve a planificar cuando el fuego avanza o cuando alguna parte de su ruta actual queda bloqueada por una celda quemada. Para realizar esta nueva búsqueda se construye una versión actualizada del mapa que considera como obstáculos tanto los muros originales como las celdas alcanzadas por el incendio. La nueva búsqueda comienza desde la posición actual del agente. Si no existe una ruta disponible, el agente permanece en su posición mientras no sea alcanzado por el fuego.

Algoritmo Genético

El Algoritmo Genético representa una estrategia distinta a los algoritmos de búsqueda tradicionales.

Cada agente posee una población de 40 individuos. Un individuo corresponde a una secuencia completa de movimientos que el agente intentará ejecutar sobre el horizonte disponible.

Cada gen puede representar una de las cinco acciones disponibles: esperar, arriba, abajo, izquierda y derecha. Inicialmente se generan aleatoriamente.

Función de Fitness

Cada individuo es simulado considerando el mapa, la propagación del incendio y el comportamiento actual de los demás agentes. A partir del resultado de esta simulación se calcula su valor de fitness:

$$fitness = N_{evacuados} \cdot R_{evacuacion} - 120 \cdot N_{muertos} + 10 \cdot rapidez + descongestion + 100 \cdot progreso$$

donde la recompensa asociada a cada evacuación se define como:

$$R_{evacuacion} = 120 \cdot N_{agentes} + 120$$

De esta forma, la cantidad de agentes evacuados constituye el criterio dominante de la función. La penalización por muerte es de 120 puntos por agente, mientras que los demás

términos actúan principalmente como criterios secundarios para diferenciar soluciones con resultados de supervivencia similares.

Rapidez: Este término representa qué tan temprano alcanza la salida el último agente evacuado respecto del horizonte máximo disponible para la simulación. Se calcula mediante:

$$rapidez = 1 - \min\left(\frac{T_{ultimo}}{H}, 1\right)$$

donde T_{ultimo} corresponde al turno en que evacúa el último superviviente y H corresponde al horizonte de la simulación. El horizonte se obtiene a partir del momento en que el fuego alcanza la salida, por lo que representa el intervalo temporal disponible antes de que la evacuación deje de ser posible.

Esta expresión normaliza la rapidez aproximadamente en el intervalo $[0,1]$. Una evacuación temprana produce un valor cercano a 1, mientras que una evacuación próxima al final del horizonte produce un valor cercano a 0. Si ningún agente logra evacuar, se asigna:

$$rapidez = 0$$

Descongestión: Primero se calcula el costo acumulado de congestión $C_{congestion}$ generado por los agentes durante todos los turnos de la simulación. Este costo se transforma mediante:

$$descongestion = \frac{1}{1 + C_{congestion}}$$

De esta manera, una solución sin congestión obtiene un valor de 1, mientras que el valor disminuye progresivamente hacia 0 a medida que aumenta la congestión. Esta transformación permite incorporar la congestión al fitness como una recompensa por mantener separados a los agentes, evitando que valores elevados del costo de congestión dominen directamente la función.

Progreso: Para medir cuánto se acerca cada agente a la salida, previamente se calculan mediante una BFS inversa las distancias mínimas desde todas las celdas transitables hacia la salida. Para cada agente se registra su distancia inicial $d_{inicial}$ y la menor distancia d_{mejor} alcanzada durante su recorrido:

$$progreso_i = \frac{d_{inicial} - d_{mejor}}{d_{inicial}}$$

El resultado se restringe al intervalo $[0,1]$. Así, un agente que no logra acercarse obtiene un progreso igual a 0, mientras que un agente que alcanza la salida obtiene un progreso igual a 1.

Finalmente, para evaluar el comportamiento conjunto se utiliza el progreso promedio de los agentes:

$$progreso = \frac{1}{N_{agentes}} \sum_{i=1}^{N_{agentes}} progreso_i$$

Los factores 10 para rapidez, 1 para descongestión y 100 para progreso fueron utilizados para mantener estos componentes como criterios secundarios frente a la supervivencia. En particular, la elevada recompensa por evacuación evita que una solución con menor congestión o mayor progreso sea considerada mejor si evacúa considerablemente menos agentes.

La penalización de 120 se escogió de forma que sea superior al aporte máximo combinado de los criterios secundarios, cuyo máximo teórico es $10 + 1 + 100 = 111$. Así, una mejora simultánea en rapidez, descongestión y progreso no compensa la pérdida de supervivencia. A partir de esta penalización se define $R_{evacuacion} = 120N_{agentes} + 120$, reforzando aún más la prioridad de evacuar agentes frente a optimizar criterios secundarios.

- Selección

Se utiliza selección por torneo. Para seleccionar un padre se escoge aleatoriamente un pequeño conjunto de individuos y se selecciona aquel con mejor fitness.

- Cruce

Los padres seleccionados se combinan mediante cruce de un punto. Se selecciona aleatoriamente una posición del cromosoma y el nuevo individuo recibe una parte del primer padre y otra del segundo.

- Mutación

Cada movimiento del cromosoma puede cambiar aleatoriamente con probabilidad:

$$P_{Mutación} = 0.02$$

La mutación permite introducir diversidad y explorar soluciones que no estaban presentes en la población inicial.

- **Elitismo**

En cada generación se evalúan los 40 individuos de la población utilizando la función de fitness. El individuo con mayor fitness se conserva directamente mediante elitismo. Para completar el resto de la nueva población se seleccionan dos padres de manera independiente mediante torneos de tres individuos elegidos aleatoriamente, en cada torneo se selecciona como padre aquel que presenta el mayor fitness. Los dos padres generan un hijo mediante cruce de un punto, tomando una parte del cromosoma del primer padre y el resto del segundo. Posteriormente, cada gen del hijo tiene una probabilidad de 0.02 de ser reemplazado por una acción aleatoria. Este procedimiento se repite hasta volver a completar una población de 40 individuos y luego comienza la siguiente generación.

Cada agente mantiene su propia población. Al evaluar los candidatos de un agente, se utilizan como contexto las mejores trayectorias disponibles para los demás agentes. De esta manera, el fitness de una secuencia no depende solamente del movimiento individual, sino también de su interacción con el comportamiento actual del grupo.

Una vez completadas las 100 generaciones, se selecciona la mejor secuencia obtenida para cada agente y todas estas secuencias se simulan conjuntamente. El resultado de esta simulación final es el utilizado para calcular las métricas experimentales del Algoritmo Genético.

Entorno experimental

Para comparar los algoritmos se utilizaron tres tipos de mapas establecidos en el enunciado, de acuerdo con los niveles de dificultad:

- **Cuello de botella:** alta presencia de obstáculos y corredores estrechos.
- **Laberinto:** densidad intermedia, con salas, corredores e intersecciones.
- **Abierto:** menor densidad de obstáculos y mayor disponibilidad de rutas alternativas.

Los mapas se generan mediante particionamiento BSP, dividiendo recursivamente el espacio en regiones rectangulares. Dentro de las regiones se generan áreas transitables y posteriormente se conectan mediante corredores, asegurando que las distintas zonas formen un entorno conectado. Los parámetros del generador se modifican según el tipo de escenario: los mapas de cuello de botella y laberinto utilizan corredores más estrechos y una mayor subdivisión, mientras que el mapa abierto utiliza regiones y corredores de mayor amplitud.

Las semillas utilizadas permiten reproducir los escenarios experimentales. Para una misma seed se genera nuevamente la misma configuración del mapa y sus elementos aleatorios, permitiendo que los distintos algoritmos sean comparados bajo condiciones equivalentes.

Las posiciones iniciales de los agentes se seleccionan entre celdas transitables alejadas de la salida. Para evitar concentrarlos artificialmente en una misma zona, las posiciones se distribuyen buscando separación entre los agentes. Por otra parte, el origen del incendio se selecciona aleatoriamente entre el tercio de celdas transitables más alejadas de la salida según distancia Manhattan. Esta decisión evita que el incendio comience inmediatamente junto a la salida y permite disponer de un intervalo efectivo de evacuación.

Se utilizaron 45 agentes por simulación porque esta cantidad genera una densidad suficiente para observar efectos de congestión e interacción entre agentes, sin elevar excesivamente el costo computacional, especialmente en el Algoritmo Genético.

Se realizaron 120 ejecuciones por cada combinación mapa–algoritmo para obtener resultados más estables frente a la variabilidad introducida por las semillas aleatorias y, al mismo tiempo, superar el mínimo de 80 iteraciones exigido para el benchmark.

Considerando los tres tipos de mapa y los cinco algoritmos evaluados, el benchmark final estuvo compuesto por 1800 simulaciones.

Tamaño del mapa	50x50
Agentes	45
Frecuencia del fuego	k = 5
Mapas	3
Algoritmos	5
Iteraciones / configuración	120
Seeds	0 – 119
Genético	
Población	40
Generaciones	100
Probabilidad mutación	0.02

Métricas de Evaluación

Tasa de supervivencia

La Tasa de Supervivencia corresponde a la proporción de agentes que consiguen evacuar antes de ser alcanzados por el fuego:

$$Tasa_{Supervivencia} = \frac{N_{Evacuados}}{N_{Agentes}}$$

Esta métrica es el principal indicador de éxito de la estrategia de evacuación.

Tiempo de Evacuación

La métrica temporal corresponde al último turno en que el último agente superviviente alcanza la salida. Para cada combinación se reporta la media, desviación estándar, valor mínimo y valor máximo.

Cuando una ejecución no posee ningún superviviente, el tiempo del último superviviente no está definido. Por esto, dichas ejecuciones se contabilizan separadamente y se excluyen del cálculo de los estadísticos temporales.

Congestión

Como métrica complementaria se utiliza el costo acumulado de congestión generado durante cada simulación.

Este valor corresponde a la suma de las penalizaciones producidas por la ocupación simultánea de la misma celda durante todos los turnos y permite analizar cómo cada estrategia distribuye a los agentes a través del entorno.

El costo de congestión es una medida acumulativa sin unidad física: valores menores indican una menor concentración simultánea de agentes, mientras que valores mayores indican una mayor acumulación de situaciones congestionadas a lo largo de la simulación.

Resultados

Los resultados obtenidos a partir de las 120 ejecuciones realizadas para cada una de las 15 combinaciones de mapa-algoritmo se presentan en la siguiente tabla:

Mapa	Algoritmo	Supervivencia	Turnos: media $\pm$ DE [mín-máx]	S/e*	Congestión
Cuello	BFS	94.43%	92.27 $\pm$ 15.92 [67–148]	1	1172.46
Cuello	DFS	8.43%	302.49 $\pm$ 83.53 [50–496]	51	6214.84
Cuello	A*	94.31%	103.43 $\pm$ 17.49 [77–152]	1	2230.58
Cuello	Greedy	93.41%	113.05 $\pm$ 23.01 [70–177]	1	901.08
Cuello	Genético	72.67%	310.50 $\pm$ 68.87 [173–550]	1	297.86
Laberinto	BFS	93.54%	94.81 $\pm$ 17.05 [69–152]	0	1278.48
Laberinto	DFS	7.19%	302.43 $\pm$ 96.49 [51–585]	55	4918.54
Laberinto	A*	93.41%	101.91 $\pm$ 18.66 [69–166]	0	2105.58
Laberinto	Greedy	91.43%	111.82 $\pm$ 25.49 [72–197]	0	1055.91
Laberinto	Genético	74.57%	314.88 $\pm$ 81.42 [185–571]	1	324.83
Abierto	BFS	96.44%	87.88 $\pm$ 13.01 [66–132]	0	1235.57
Abierto	DFS	8.06%	272.08 $\pm$ 96.51 [44–417]	60	4868.03
Abierto	A*	97.02%	93.33 $\pm$ 14.82 [67–154]	0	1980.26
Abierto	Greedy	96.41%	100.65 $\pm$ 22.64 [63–169]	0	1051.63
Abierto	Genético	93.15%	253.75 $\pm$ 49.62 [159–422]	0	73.62

***S/e:** Sin evacuados

Estos valores corresponden a 120 experimentos para cada una de las 15 combinaciones de mapa-algoritmo.




Figura 1: Tasa de supervivencia según mapa y algoritmo




Figura 2: Tiempo medio hasta la evacuación del último superviviente




Figura 3: Congestión acumulada promedio según mapa y algoritmo.

Análisis de los Resultados

Los resultados muestran una diferencia considerable entre DFS y el resto de los algoritmos de búsqueda. BFS alcanzó una supervivencia promedio cercana al 94.8%, mientras que A* obtuvo aproximadamente 94.91%. Greedy también presentó un rendimiento elevado, con aproximadamente 93.75%.

Las diferencias entre estos tres algoritmos son reducidas, por lo que los resultados permiten afirmar que los tres mantuvieron tasas de supervivencia elevadas, pero no resulta conveniente interpretar pequeñas diferencias porcentuales como evidencia suficiente de superioridad de uno sobre otro.

BFS encuentra rutas con un número mínimo de movimientos en la grilla de costo unitario, mientras que A* combina el costo acumulado con la heurística Manhattan. Greedy prioriza únicamente la estimación heurística hacia la salida. A pesar de estas diferencias, los tres algoritmos lograron evacuar a la mayoría de los agentes en los tres tipos de escenario.

DFS presentó un comportamiento considerablemente distinto. Su supervivencia media global fue de aproximadamente 7.89%. Además, de sus 360 ejecuciones, 166 finalizaron sin ningún agente evacuado. Su estrategia de búsqueda en profundidad puede producir rutas considerablemente más largas que las encontradas por los demás métodos, lo que resulta

especialmente desfavorable en un entorno dinámico donde el fuego puede bloquear partes de una ruta antes de que esta sea completada.

Comportamiento del Algoritmo Genético

El Algoritmo Genético presentó una tasa media global de supervivencia cercana al 80.13%, inferior a BFS, A* y Greedy, pero considerablemente superior a DFS. Su comportamiento varió según la topología del mapa. En cuello de botella alcanzó un 72.67% de supervivencia y en laberinto un 74.57%, mientras que en el escenario abierto aumentó hasta 93.15%.

Esto indica que las secuencias evolucionadas obtuvieron mejores resultados cuando existían múltiples rutas disponibles hacia la salida y una menor dependencia de corredores críticos. El Genético también presentó los menores niveles de congestión de los cinco algoritmos. Sus valores promedio fueron 297.86 en cuello de botella, 324.83 en laberinto y solamente 73.62 en el mapa abierto.

Este comportamiento es coherente con su función de fitness, que incorpora explícitamente la congestión como uno de sus criterios secundarios. Sin embargo, una menor congestión no implica necesariamente una mejor evacuación. En los mapas de cuello de botella y laberinto, el Genético produjo menos congestión que los algoritmos tradicionales, pero su tasa de supervivencia fue también menor. Por este motivo ambas métricas deben analizarse conjuntamente.

La topología del escenario también influyó en los resultados generales. El mapa abierto produjo las mayores tasas de supervivencia para BFS, A*, Greedy y Genético, mientras que los escenarios con corredores y obstáculos limitaron las rutas alternativas disponibles ante la propagación del fuego.

Conclusiones

Los experimentos muestran que la estrategia utilizada para planificar las rutas influye considerablemente en el resultado de una evacuación dentro de un entorno dinámico.

BFS, A* y Greedy Best-First mantuvieron tasas de supervivencia superiores al 90% en los tres tipos de mapa. BFS y A* obtuvieron resultados particularmente similares, mientras que Greedy presentó una ligera disminución en los escenarios de mayor complejidad topológica.

DFS obtuvo los resultados de supervivencia más bajos. Su tendencia a profundizar en una ruta antes de explorar alternativas puede generar trayectorias extensas, lo que resulta desfavorable cuando el entorno cambia progresivamente por efecto del incendio.

El Algoritmo Genético mostró un comportamiento intermedio. Su desempeño fue inferior al de BFS, A* y Greedy en cuello de botella y laberinto, pero alcanzó una supervivencia de

93.15% en el mapa abierto. Además, presentó los menores niveles de congestión en los tres escenarios evaluados.

Finalmente, los resultados muestran que la topología del mapa condiciona el desempeño de las estrategias de evacuación. Los escenarios abiertos permiten una mayor cantidad de rutas alternativas, mientras que los corredores estrechos y puntos críticos aumentan las consecuencias de la propagación del fuego y de la concentración de agentes.

Uso de IA Generativa

Durante el desarrollo de la tarea se utilizaron herramientas de IA generativa, principalmente ChatGPT y Claude, como apoyo en la implementación y revisión de fragmentos de código, detección de errores, optimización de la implementación del Algoritmo Genético, análisis de resultados y revisión de la redacción del informe. Los resultados experimentales presentados fueron obtenidos mediante la ejecución local del código disponible en el repositorio del proyecto.